

PROJEÇÃO DE OCUPAÇÃO E RISCO DE REINCIDÊNCIA NO SISTEMA PRISIONAL BRASILEIRO: UMA PROPOSTA DE CIÊNCIA DE DADOS PARA APOIO À GESTÃO PENITENCIÁRIA

PROJECTION OF PRISON OCCUPANCY AND RECIDIVISM RISK IN THE BRAZILIAN PRISON SYSTEM: A DATA SCIENCE PROPOSAL FOR PENITENTIARY MANAGEMENT SUPPORT

Resumo

O sistema prisional brasileiro enfrenta uma crise estrutural de superlotação, agravada por altas taxas de reincidência e pela ausência de instrumentos de gestão capazes de antecipar a pressão sobre a capacidade das unidades. Este artigo apresenta a fundamentação teórica e metodológica de um projeto de ciência de dados voltado à projeção de ocupação carcerária por unidade prisional e à estimativa de risco agregado de reincidência, com base em dados públicos do Departamento Penitenciário Nacional (DEPEN), do Conselho Nacional de Justiça (CNJ) e da Secretaria da Administração Penitenciária de São Paulo (SAP-SP). São apresentados o problema de pesquisa, os objetivos geral e específicos, a justificativa teórica e empírica do projeto, a fundamentação teórica, os trabalhos relacionados nacionais e internacionais, a metodologia geral adotada — a Design Science Research Methodology (DSRM) — e, nesta segunda versão, o detalhamento da etapa de Design e Desenvolvimento do artefato: os dados reais utilizados, o pré-processamento e a engenharia de atributos, os modelos baseline treinados e as métricas obtidas em um primeiro MVP analítico.

Palavras-chave: Sistema prisional. Superlotação carcerária. Reincidência criminal. Ciência de dados. Gestão penitenciária. Design Science Research.

1. Introdução

O encarceramento em massa é um dos fenômenos mais persistentes da política criminal brasileira nas últimas três décadas. A população prisional do país cresceu de forma acentuada desde o ano 2000, quando o primeiro levantamento sistemático do Departamento Penitenciário Nacional (DEPEN) registrava 232.755 pessoas presas para apenas 135.710 vagas disponíveis (POLITIZE!, 2024). Em junho de 2016, o total de pessoas encarceradas já havia chegado a 726.712, um crescimento de mais de 100 mil pessoas em relação a dezembro de 2014 (AGÊNCIA BRASIL, 2017). Estimativas mais recentes indicam uma população carcerária próxima de 900 mil pessoas em 2024, o que representa um crescimento de quase 900% desde 1990 (MIGALHAS, 2025).

Esse crescimento não foi acompanhado por expansão proporcional da infraestrutura penitenciária. Levantamentos do próprio DEPEN indicam que 89% da população prisional brasileira está custodiada em unidades com déficit de vagas, atingindo 78% dos estabelecimentos penais do país (AGÊNCIA BRASIL, 2017; JUSBRASIL, 2025). Dados mais

recentes do InfoPen apontam déficit superior a 230 mil vagas em âmbito nacional, com unidades de detenção provisória operando, em alguns estados, com até três vezes mais presos que sua capacidade declarada (FEF, [s.d.], apud DEPEN, 2023; MENEZES, 2022). Em estados como Amazonas, Pernambuco e Rio Grande do Sul, a taxa de ocupação ultrapassa 200% da capacidade instalada (FEF, [s.d.]). O Conselho Nacional de Justiça (CNJ) já destacou que cerca de 70% dos estabelecimentos penais do país operam com déficit de vagas, evidenciando que a superlotação é um componente estrutural, e não pontual, da crise penitenciária brasileira (FEF, [s.d.]).

Paralelamente à superlotação, a reincidência criminal figura como outro indicador crítico da efetividade do sistema prisional. A mensuração desse fenômeno, no entanto, é historicamente controversa: cifras amplamente divulgadas na imprensa e em discursos institucionais chegam a apontar taxas de 70% (GESTÃO DO SISTEMA PRISIONAL, [s.d.]), enquanto estudos técnicos com metodologia mais rigorosa apresentam números substancialmente menores. O estudo conduzido pelo Instituto de Pesquisa Econômica Aplicada (IPEA) a pedido do CNJ, considerando reincidência legal (nova condenação em até cinco anos após o cumprimento da pena), identificou uma taxa de 24,4% (CNJ, 2015). Já o relatório do CNJ de 2019, que adotou critério mais amplo, considerando qualquer retorno ao sistema de justiça criminal, apontou reincidência de 42,5% (MIGALHAS, 2025). Essa variação demonstra que a taxa de reincidência é altamente sensível à definição operacional adotada, o que reforça a necessidade de qualquer estudo sobre o tema explicitar com clareza seu critério de mensuração.

No campo da segurança pública brasileira, técnicas de ciência de dados e aprendizado de máquina já vêm sendo empregadas para apoiar decisões operacionais, como a alocação preventiva de policiamento com base em modelos preditivos de ocorrências criminais (REVISTA FT, [s.d.]). Esse precedente metodológico sugere que abordagens semelhantes — séries temporais e modelos de classificação supervisionada — podem ser aplicadas ao contexto da gestão penitenciária, deslocando o uso da ciência de dados do policiamento ostensivo para o planejamento administrativo do sistema prisional, com o objetivo de antecipar, e não apenas registrar, a pressão sobre a capacidade das unidades.

2. Problema

Os dados oficiais disponíveis sobre o sistema prisional brasileiro — notadamente o InfoPen (DEPEN) e o Banco Nacional de Monitoramento de Prisões, BNMP (CNJ) — são, por concepção, instrumentos de diagnóstico retrospectivo. O próprio DEPEN reconhece que o levantamento sintetiza informações sobre os estabelecimentos penais e a população prisional, mas não esgota as possibilidades de análise dos dados coletados (INFOPEN, [s.d.]). Isso significa que, embora exista um volume histórico considerável de dados sobre capacidade, população e movimentação carcerária, esse volume é predominantemente utilizado para

descrever o estado atual ou passado do sistema, e não para projetar sua trajetória futura em nível de unidade prisional individual.

Essa lacuna tem consequências práticas relevantes para a gestão: decisões sobre transferência de custodiados, priorização de mutirões carcerários, construção de novas unidades ou direcionamento de programas de ressocialização tendem a ser tomadas de forma reativa, após a superlotação já se manifestar, e não de forma antecipatória. De modo semelhante, a reincidência — quando mensurada — costuma ser reportada em estudos nacionais amplos e pontuais (como os relatórios do IPEA/CNJ de 2015 e do CNJ de 2019), sem desdobramento sistemático e contínuo por unidade prisional ou por perfil demográfico que permita à gestão estadual direcionar recursos de forma diferenciada.

Diante desse cenário, formula-se o seguinte problema de pesquisa: dado o histórico de entradas, saídas, capacidade declarada e reincidência disponível nas bases públicas do DEPEN e do CNJ, é possível construir um modelo que projete a ocupação de cada unidade prisional de um sistema estadual nos próximos 6 a 12 meses e que identifique, em nível agregado, os perfis com maior risco de retorno ao sistema prisional dentro de uma janela de 24 meses após a saída?

3. Objetivos

3.1 Objetivo geral

Desenvolver um modelo de projeção de fluxo carcerário por unidade prisional, associado a um modelo de risco agregado de reincidência, consolidados em um painel de apoio à decisão voltado à gestão do sistema prisional estadual.

3.2 Objetivos específicos

- a) Consolidar e mensurar a taxa de ocupação histórica (população carcerária em relação à capacidade declarada) por unidade prisional, a partir dos dados do InfoPen (DEPEN).
- b) Construir e validar um modelo de série temporal capaz de projetar a taxa de ocupação de cada unidade prisional em um horizonte de 6 a 12 meses.
- c) Definir operacionalmente o critério de reincidência a ser utilizado, com base no histórico de entradas e saídas registrado no Banco Nacional de Monitoramento de Prisões (BNMP), e construir um modelo de classificação para estimar o risco agregado de reincidência por perfil (regime, tipo penal, faixa etária, tempo de pena e unidade prisional).
- d) Avaliar possíveis vieses e limitações éticas dos atributos utilizados no modelo de reincidência, restringindo seu uso a decisões de política pública em nível agregado.

e) Consolidar os resultados dos dois modelos em um painel interativo único, destinado a gestores do sistema prisional estadual.

4. Justificativa

A justificativa deste projeto assenta-se em três dimensões: a magnitude do problema, a lacuna metodológica identificada nos instrumentos de gestão atualmente disponíveis, e a viabilidade técnica de aplicação de métodos de ciência de dados já validados em contextos correlatos de segurança pública no Brasil.

Em termos de magnitude, os dados oficiais deixam pouca margem de dúvida quanto à gravidade da superlotação carcerária brasileira: déficit superior a 230 mil vagas (FEF, [s.d.], apud DEPEN, 2023), 89% da população prisional em unidades com déficit de vagas (AGÊNCIA BRASIL, 2017) e taxas de ocupação superiores a 200% em determinados estados (FEF, [s.d.]). Esses números configuram, segundo o próprio CNJ, uma condição estrutural e não conjuntural da política penitenciária brasileira, com efeitos diretos sobre a dignidade da pessoa presa e sobre a efetividade da execução penal (FEF, [s.d.]).

Quanto à lacuna metodológica, observa-se que, apesar de o Brasil dispor de bases de dados públicas relativamente robustas desde 2004 (INFOPEN, [s.d.]), a literatura consultada não indica a existência de instrumentos amplamente utilizados pela gestão estadual para projeção contínua e desagregada por unidade prisional. Some-se a isso a constatação, já apontada por pesquisadores do próprio CNJ, de que a apuração da taxa de reincidência é de difícil mensuração e sujeita a variações metodológicas relevantes — de 24,4% a 42,5%, a depender do critério adotado (CNJ, 2015; MIGALHAS, 2025). Essa imprecisão reforça a necessidade de um projeto que explicita, documente e valide sua própria definição operacional de reincidência, em vez de reproduzir acriticamente cifras de origem incerta, como o percentual de 70% frequentemente citado em discursos institucionais sem lastro metodológico comprovado (GESTÃO DO SISTEMA PRISIONAL, [s.d.]).

Por fim, quanto à viabilidade técnica, a aplicação de modelos de aprendizado de máquina e séries temporais para apoio a decisões de segurança pública já conta com precedentes na literatura brasileira, como estudos de policiamento preditivo baseados em algoritmos de classificação supervisionada aplicados a ocorrências criminais (REVISTA FT, [s.d.]). A adaptação dessas técnicas ao contexto da gestão penitenciária — substituindo a alocação de policiamento pela alocação de vagas, transferências e programas de ressocialização — representa uma extensão metodologicamente factível e ainda pouco explorada no país, com potencial de transformar dados hoje utilizados apenas de forma descritiva em um instrumento efetivo de planejamento antecipatório para a gestão pública.

5. Fundamentação Teórica

Este projeto articula quatro blocos conceituais: (i) a mensuração da superlotação carcerária como razão entre população e capacidade declarada por unidade; (ii) a mensuração da reincidência criminal, cuja definição operacional varia entre critérios legais (nova condenação) e critérios amplos (qualquer retorno ao sistema de justiça criminal), conforme evidenciado pela divergência entre os relatórios do CNJ/IPEA (2015) e do CNJ (2019) já discutida na Introdução; (iii) métodos de projeção de séries temporais, empregados para estimar a trajetória futura da ocupação de cada unidade prisional a partir de seu histórico; e (iv) métodos de classificação supervisionada, empregados para estimar a probabilidade de reincidência a partir de atributos observáveis no momento da saída do sistema prisional.

Do ponto de vista metodológico geral da pesquisa, adota-se a Design Science Research Methodology (DSRM), formalizada por Peffers, Tuunanen, Rothenberger e Chatterjee (2007). A DSRM organiza a pesquisa em ciência de dados/sistemas de informação em seis atividades: identificação do problema e motivação; definição dos objetivos de uma solução; concepção e desenvolvimento do artefato; demonstração; avaliação; e comunicação dos resultados. Diferentemente de metodologias puramente descritivas, a DSRM é orientada à construção de um artefato — neste caso, o painel de projeção de ocupação e risco de reincidência — que deve resolver um problema prático real e ser avaliado quanto à sua utilidade, não apenas quanto à sua correção teórica (PEFFERS et al., 2007).

6. Trabalhos Relacionados

No cenário internacional, o principal precedente de uso de modelos preditivos para risco de reincidência é o sistema COMPAS (Correctional Offender Management Profiling for Alternative Sanctions), utilizado por tribunais de diversos estados norte-americanos para subsidiar decisões sobre fiança e sentença. Em 2016, uma investigação da organização de jornalismo investigativo ProPublica, conduzida por Angwin e colaboradores, identificou que o algoritmo apresentava taxas de falso positivo significativamente mais altas para réus negros do que para réus brancos, atribuindo o dobro de chance de classificação equivocada como futuro reincidente aos primeiros (ANGWIN et al., 2016). O episódio tornou-se referência obrigatória na literatura sobre viés algorítmico em justiça criminal e é central para a decisão de projeto, já documentada na Justificativa e reiterada na seção de Metodologia, de restringir o uso do modelo de reincidência deste trabalho a decisões agregadas de política pública, nunca a decisões individuais sobre uma pessoa específica.

No cenário brasileiro, ainda que a aplicação de ciência de dados à gestão penitenciária seja pouco explorada, há precedentes relevantes de uso de aprendizado de máquina em segurança pública, como o estudo sobre policiamento preditivo na região metropolitana de São Luís, que avaliou o desempenho de um algoritmo Random Forest na predição de ocorrências de

roubo por zona geográfica (REVISTA FT, [s.d.]). Esse trabalho demonstra a viabilidade técnica de modelos supervisionados aplicados a dados públicos de segurança no país, mas concentra-se na alocação de policiamento ostensivo, e não na gestão da capacidade ou da reincidência do sistema prisional — lacuna que este projeto busca preencher.

A revisão da literatura e dos relatórios governamentais consultados não identificou, até o momento, um instrumento brasileiro amplamente documentado que combine projeção contínua de ocupação por unidade prisional com estimativa agregada de risco de reincidência em um único painel de apoio à decisão, o que reforça a contribuição pretendida deste trabalho.

7. Metodologia — Visão Geral

Conforme apresentado na Fundamentação Teórica, este projeto segue as seis atividades da DSRM (PEFFERS et al., 2007), mapeadas da seguinte forma:

- a) Identificação do problema e motivação — corresponde às seções 1 e 2 deste artigo (Introdução e Problema), fundamentadas nos dados de superlotação e reincidência do DEPEN e do CNJ.
- b) Definição dos objetivos de uma solução — corresponde à seção 3 (Objetivos geral e específicos).
- c) Concepção e desenvolvimento do artefato — compreende o levantamento e a ingestão das bases de dados públicas (InfoPen, BNMP, SAP-SP, IBGE), a engenharia de atributos e a construção dos dois modelos centrais do projeto: um modelo de séries temporais para projeção de ocupação por unidade prisional e um modelo de classificação supervisionada para risco agregado de reincidência. O detalhamento desta atividade, incluindo o ciclo de vida de aprendizado de máquina executado no MVP analítico da segunda sprint do projeto, é apresentado na Seção 8.
- d) Demonstração — consiste na aplicação do artefato ao estado-piloto (São Paulo), consolidando os resultados em um painel interativo único.
- e) Avaliação — realizada por meio de métricas quantitativas de desempenho preditivo (erro percentual médio absoluto para o modelo de ocupação; área sob a curva ROC e demais métricas de classificação para o modelo de reincidência) e por validação qualitativa junto a pelo menos um gestor público ou pesquisador da área.
- f) Comunicação — corresponde à publicação deste artigo, à documentação do repositório de código e à disponibilização do painel aos stakeholders identificados na Justificativa.

O projeto é conduzido de forma incremental, em sprints. A Sprint 1 (Conhecendo os Dados) correspondeu ao levantamento e caracterização das fontes de dados públicas, à análise

exploratória preliminar e à priorização do backlog de requisitos. A Sprint 2 (MVP Analítico), detalhada na Seção 8, corresponde ao início efetivo da atividade (c) da DSRM: pré-processamento, engenharia de atributos e treinamento de um primeiro conjunto de modelos baseline.

8. Metodologia Detalhada — Dados, Pré-processamento, Modelos e Métricas (Sprint 2)

Esta seção detalha a execução da atividade (c) da DSRM — concepção e desenvolvimento do artefato — na etapa correspondente ao ciclo de vida de aprendizado de máquina: aquisição e caracterização dos dados, pré-processamento, engenharia de atributos, treinamento e comparação de modelos baseline, e exportação do artefato treinado. Na DSRM, esta etapa não é um evento único, mas um subciclo iterativo dentro da fase de Design e Desenvolvimento: cada rodada de modelagem gera aprendizado sobre a adequação dos dados e das features, que retroalimenta o refinamento do artefato antes da Demonstração formal (fase d).

8.1 Dados utilizados no MVP analítico

Diferentemente da base bruta completa por unidade e por mês, prevista para as próximas sprints mediante a ingestão automatizada do InfoPen e do BNMP (ver Seção 2), o MVP analítico desta sprint foi construído sobre quatro conjuntos de dados reais, já documentados no levantamento de datasets do projeto: (i) uma série histórica nacional de população prisional e razão pessoas por vaga, 2007–2019, extraída de um artigo peer-reviewed publicado em Cadernos de Saúde Pública com base em dados do INFOPEN/DEPEN; (ii) uma série histórica anual da população prisional de São Paulo, 2022–2025, publicada pela SAP-SP; (iii) um snapshot real de 10 sub-unidades prisionais paulistas, com capacidade e população em data-base única; e (iv) um relatório estatístico oficial da SAP-SP com o perfil da população carcerária do estado. Nenhum dado utilizado é simulado; a limitação reconhecida é o tamanho da amostra (17 pontos de série temporal e 10 unidades), não a natureza dos dados.

8.2 Pré-processamento e engenharia de atributos

O pré-processamento, implementado no módulo `src/features/preprocessamento_sprint2.py` do repositório do projeto, produziu duas tabelas de atributos. Para a série temporal, foram calculados atributos de defasagem (população do ano/período anterior), taxa de crescimento percentual ano a ano e média móvel de três períodos — este último atributo é, ele próprio, um dos modelos baseline comparados na Seção 8.3. Para as unidades prisionais, foram calculados a taxa de ocupação (população dividida pela capacidade declarada), o logaritmo da capacidade (para reduzir a assimetria da variável) e a codificação one-hot do tipo de unidade (Penitenciária, Centro de Detenção Provisória, Ala de

Progressão Penitenciária, Pavilhão de Regime Semiaberto). O rótulo binário de interesse, unidade crítica, foi definido como taxa de ocupação igual ou superior a 150% da capacidade — o mesmo limiar já utilizado no painel de alertas definido no Canvas do projeto.

8.3 Modelos baseline treinados e comparados

Para a projeção de população/ocupação, três modelos foram comparados com separação temporal treino/teste (treino: 2007–2016; teste: 2017–2019, nunca visto no treino): um baseline Naive de persistência (projeta o último valor observado), um baseline de média móvel de três anos, e uma Regressão Linear simples (ano como variável explicativa). Para a classificação de unidade crítica, dado o tamanho reduzido da amostra (10 unidades), foi utilizada validação cruzada Leave-One-Out (LOO) em vez de um único split treino/teste, comparando um classificador Dummy (que sempre prevê a classe majoritária) com uma Regressão Logística sobre o logaritmo da capacidade e o tipo de unidade.

8.4 Métricas e resultados

A Tabela 1 apresenta os resultados de erro absoluto médio (MAE) e erro percentual absoluto médio (MAPE) dos três modelos de projeção no conjunto de teste (2017–2019):

Modelo	MAE	MAPE (%)
Naive (persistência)	23.587	3,19%
Média móvel (3 anos)	42.287	5,85%
Regressão Linear	27.366	3,73%

Diferentemente do que se poderia supor, o baseline Naive obteve o menor erro entre os três modelos nesse teste específico. A explicação mais provável, à luz da série real, é uma desaceleração do crescimento populacional entre 2016 e 2019 em relação à tendência observada em 2007–2016: o modelo de Regressão Linear, ajustado sobre uma tendência de crescimento mais acentuada no período de treino, superestimou o crescimento nos três anos de teste, enquanto o baseline Naive, ao assumir estabilidade, aproximou-se mais do valor real nesse trecho específico da série. Esse resultado real é tratado como um achado relevante, não como uma falha do experimento: reforça, com evidência empírica, a limitação — já antecipada na Fundamentação Teórica — de modelos de tendência simples diante de possíveis mudanças estruturais na trajetória do encarceramento, e orienta a exploração de modelos com maior capacidade de adaptação (ex. suavização exponencial ou modelos com variáveis exógenas) nas próximas sprints.

A Tabela 2 apresenta os resultados da classificação de unidade crítica, com validação Leave-One-Out (LOO):

Modelo	Acurácia (LOO)	F1-score
Dummy (classe majoritária)	60%	0,75
Regressão Logística	100%	1,00

A Regressão Logística superou o baseline Dummy na validação LOO, mas a acurácia perfeita obtida deve ser interpretada com cautela metodológica: com apenas 10 observações, um classificador pode separar a amostra quase perfeitamente por padrões espúrios (por exemplo, associados ao tipo de unidade), sem que isso indique capacidade real de generalização. O resultado desta sprint valida o pipeline de treinamento, avaliação e exportação do artefato — não a adequação do modelo para uso em produção, o que só poderá ser avaliado com a base completa por unidade prevista para as próximas sprints.

8.5 Exportação e versionamento do artefato

Os dois modelos finais — Regressão Linear (projeção de população) e Regressão Logística (classificação de unidade crítica), retreinados com a totalidade dos dados disponíveis após a etapa de comparação — foram serializados em formato joblib e armazenados na pasta `models/` do repositório do projeto, com sufixo de versão explícito (`_v1`), permitindo a comparação sistemática com versões futuras treinadas em bases de maior volume, em linha com a prática de versionamento de artefatos recomendada em projetos de ciência de dados conduzidos sob a ótica de Design Science Research.

Referências

- AGÊNCIA BRASIL. Com 726 mil presos, Brasil tem terceira maior população carcerária do mundo. Brasília, 8 dez. 2017. Disponível em: <https://agenciabrasil.ebc.com.br/geral/noticia/2017-12/populacao-carceraria-do-brasil-sobe-de-622202-para-726712-pessoas>. Acesso em: 11 ago. 2026.
- ANGWIN, Julia; LARSON, Jeff; MATTU, Surya; KIRCHNER, Lauren. Machine Bias. ProPublica, 23 maio 2016. Disponível em: <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>. Acesso em: 18 ago. 2026.
- CONSELHO NACIONAL DE JUSTIÇA (CNJ). Um em cada quatro condenados reincide no crime, aponta pesquisa. Portal CNJ, 2015. Disponível em: <https://www.cnj.jus.br/um-em-cada-quatro-condenados-reincide-no-crime-aponta-pesquisa/>. Acesso em: 11 ago. 2026.
- DEPARTAMENTO PENITENCIÁRIO NACIONAL (DEPEN). Infopen — Levantamento Nacional de Informações Penitenciárias. [s.d.]. Disponível em: <http://antigo.depen.gov.br/DEPEN/depen/sisdepen/infopen>. Acesso em: 11 ago. 2026.
- FEF. Crise do sistema prisional brasileiro: superlotação, violação de direitos e alternativas de execução penal. [s.d.]. Disponível em: https://fef.br/upload_arquivos/geral/arq_698de025274c6.pdf. Acesso em: 11 ago. 2026.

- GESTÃO DO SISTEMA PRISIONAL (GSP/UFG). Quantos ex-detentos voltam a cometer crimes? [s.d.]. Disponível em: <https://gsp.direito.ufg.br/n/196655-quantos-ex-detentos-voltam-a-cometer-crimes>. Acesso em: 11 ago. 2026.
- JUSBRASIL. Superlotação: uma análise da questão carcerária brasileira em face da legislação e direitos humanos. 2025. Disponível em: <https://www.jusbrasil.com.br/artigos/superlotacao-uma-analise-da-questao-carceraria-brasileira-em-face-da-legislacao-e-direitos-humanos/5306129821>. Acesso em: 11 ago. 2026.
- MIGALHAS. Ressocialização ainda é um desafio no sistema prisional brasileiro. 2025. Disponível em: <https://www.migalhas.com.br/quentes/423567/ressocializacao-ainda-e-um-desafio-no-sistema-prisional-brasileiro>. Acesso em: 11 ago. 2026.
- PEFFERS, Ken; TUUNANEN, Tuure; ROTHENBERGER, Marcus A.; CHATTERJEE, Samir. A Design Science Research Methodology for Information Systems Research. *Journal of Management Information Systems*, v. 24, n. 3, p. 45-77, 2007.
- POLITIZE! Sistema carcerário brasileiro: a realidade das prisões no Brasil. 2024. Disponível em: <https://www.politize.com.br/sistema-carcerario-brasileiro/>. Acesso em: 11 ago. 2026.
- REVISTA FT. Policiamento preditivo e inteligência artificial: análise de desempenho do algoritmo de aprendizado de máquina supervisionado Random Forest na predição de ocorrências policiais de roubo nas zonas da região metropolitana de São Luís. [s.d.]. Disponível em: <https://revistaft.com.br/policiamento-preditivo-e-inteligencia-artificial-analise-de-desempenho-do-algoritmo-de-aprendizado-de-maquina-supervisionado-random-forest-na-predicao-de-ocorrencias-policiais-de-roubo-nas-zonas-da-r/>. Acesso em: 11 ago. 2026.
- SECRETARIA DA ADMINISTRAÇÃO PENITENCIÁRIA DE SÃO PAULO (SAP-SP). Dados Estatísticos da População Carcerária Masculina e Feminina — base 30/06/2025. Disponível em: https://www1.sap.sp.gov.br/dados-abertos/dados-estatisticos-populacao-prisional-geral_1-sem-2025.pdf. Acesso em: 18 ago. 2026.
- SAP-SP. Unidades Prisionais — dados de capacidade e população por unidade. Disponível em: <https://www1.sap.sp.gov.br/uni-prisionais/pen-.html>. Acesso em: 18 ago. 2026.